Attention Is All You Need 간략 보고서

OpenClaw Auto Brief

March 31, 2026

1 한 줄 요약

Attention Is All You Need (Vaswani et al., 2017)은 RNN/CNN 없이 **Self-Attention**만으로 시퀀스 변환을 수행하는 Transformer를 제안했고, 이는 현대 LLM의 핵심 아키텍처 표준이 되었다.

2 문제의식

기존 Seq2Seq(RNN 기반)는 다음 한계가 있었다.

- 장거리 의존성 학습이 어렵다.
- 순차 처리 특성상 학습 병렬화가 제한적이다.
- 학습 시간/비용이 크다.

논문은 이를 해결하기 위해 토큰 간 관계를 직접 계산하는 Attention 중심 구조를 제시했다.

3 핵심 아이디어

3.1 Transformer 인코더-디코더

모델은 인코더/디코더 블록을 쌓는 구조이며, 각 블록은 다음으로 구성된다.

- Multi-Head Self-Attention
- Position-wise Feed-Forward Network
- Residual Connection + Layer Normalization

3.2 Scaled Dot-Product Attention

Q, K, V를 사용해 토큰 간 중요도를 계산한다.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$\sqrt{d_k}$로 스케일링해 큰 차원에서 softmax가 과도하게 뾰족해지는 문제를 완화한다.

3.3 Multi-Head Attention

하나의 attention 대신 여러 head를 병렬로 사용해 서로 다른 관계(문법적/의미적/장거리 의존성)를 동시에 포착한다.

3.4 Positional Encoding

RNN이 없으므로 순서 정보를 명시적으로 주입한다. 사인/코사인 기반 positional encoding을 더해 토큰 순서를 표현한다.

4 주요 결과와 의의

WMT 2014 번역 과제(EN-DE, EN-FR)에서 강력한 성능을 보였고, 동시에 학습 병렬화 효율을 크게 개선했다. 핵심 의의는 다음과 같다.

- 시퀀스 모델링의 중심을 recurrence에서 attention으로 이동
- 대규모 사전학습(Pretraining) 기반 언어모델 발전의 토대 제공
- BERT, GPT 계열을 포함한 현대 LLM 아키텍처의 직접적 기반

5 제한점과 후속 연구

원 논문 이후 알려진 대표적 한계:

- Self-Attention의 $O(n^2)$ 메모리/연산 비용
- 긴 문맥에서의 비용 증가

이를 해결하기 위해 Sparse/Linear Attention, FlashAttention, 긴 컨텍스트 최적화 연구가 활발히 진행됐다.

6 실무 관점 정리

1. Transformer 이해는 LLM 이해의 출발점이다.
2. 모델 성능뿐 아니라 **학습/추론 효율**이 중요하다.
3. Attention 메커니즘과 토크나이징/포지셔널 설계는 실제 성능에 큰 영향을 준다.

참고 문헌

Vaswani, A., et al. (2017). *Attention Is All You Need*. NeurIPS 2017.